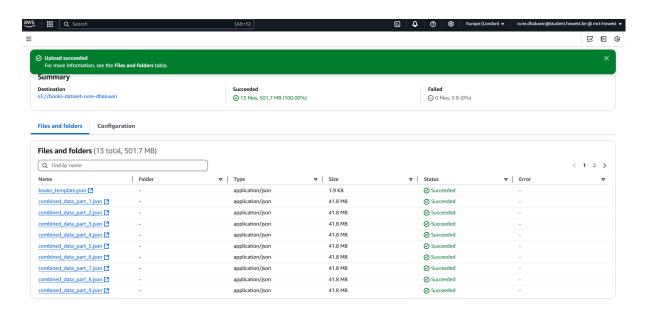
Opdracht

Er is al een werkend docker compose project voorzien, je hoeft in principe niets te wijzigen aan wat er al gegeven is! In mijn repo is er een mapje logstash met daarin 2 mapjes: data en pipeline. In het mapje pipeline zit het bestand books.conf (Die jij zelf zult moeten maken). In het mapje data zitten verschillende json bestanden (combined_data_part_1.json, combined_data_part_2.json, ..., tot en met combined_data_part_12.json) en een bestand books_template.json (De combined_data_part_1.json tot en met combined_data_part_12.json bevat dus de hele dataset over boeken.

1. Gebruik cloud storage:

Kies een cloud oplossing en zorg dat de data in de cloud word opgeslagen in plaats van lokaal

Mijn oplossing: AWS S3 Bucket aangemaakt en alle json files daarin geüpload



2. Importeer de data:

Zoek uit hoe je de data kunt verwerken met de Elastic Stack. De data moet uiteraard opgeslagen worden in Elasticsearch! De verwerking van de data moet

voldoen aan enkele specifieke vereisten:

- De data moet worden opgeslagen in een index genaamd: books_dataset.
- Maak gebruik van de meegeleverde template:
 - template_name: "books"
 - o template ⇒ "<path>books_template.json" (<path> = placeholder)
 - template_overwrite ⇒ true
- Bekijk de dataset en zorg ervoor dat jouw output overeenkomt met de gegeven voorbeelden. Je data moet exact hetzelfde formaat hebben! Dit betekent dat je enkele filters nodig zult hebben om dit te bereiken! Wees kritisch en let goed op de details! het is prima als de volgorde van de velden licht verschilt, maar uiteindelijk moet je wel dezelfde velden hebben als in de voorbeelden!
- Het is belangrijk dat je pipeline efficient is.
- TIPS!: gebruik meerdere mutate filters, maak het op zo'n eenvoudige manier mogelijk.

Mijn oplossing:

ik heb nu een basic pipeline die de data uit mijn amazon bucket haalt en hem weer geeft en een .env bestand gemaakt waarbij mijn geheime keys etc komen, deze staat in mijn .gitignore en .dockerignore

```
input {
    s3 {
      bucket ⇒ "books-dataset-rune-dhaluwin"
      prefix ⇒ ""
    region ⇒ "${AWS_REGION}"
    access_key_id ⇒ "${AWS_ACCESS_KEY_ID}"
    secret_access_key ⇒ "${AWS_SECRET_ACCESS_KEY}"
    codec ⇒ "json_lines"
    }
}

filter {
    # hier komen de mutaties
```

```
output {
  stdout { codec ⇒ rubydebug }
}
```

Als ik dan de logstash al run via deze commands krijg ik dit resultaat (dus de data komt nu binnen vanuit mijn amazon bucket):

docker compose exec logstash /bin/bash

logstash -f /usr/share/logstash/pipeline/books.conf --config.reload.automatic

Nu heb ik gezorgd dat het correct word gefilterd en de output goed staat:

```
input {
  s3 {
    bucket ⇒ "books-dataset-rune-dhaluwin"
    prefix ⇒ ""
  region ⇒ "${AWS_REGION}"
  access_key_id ⇒ "${AWS_ACCESS_KEY_ID}"
```

```
secret_access_key ⇒ "${AWS_SECRET_ACCESS_KEY}"
  codec ⇒ "json_lines"
 }
}
filter {
 # Step 1: Split user location into separate fields (city, state, country)
 mutate {
  split \Rightarrow \{ "[user][location]" \Rightarrow ", " \}
  add_field ⇒ {
   "[user][city]" ⇒ "%{[user][location][0]}"
   "[user][state]" ⇒ "%{[user][location][1]}"
   "[user][country]" \Rightarrow "%{[user][location][2]}"
  }
 }
 # Step 2: Clean up - remove the original location field
 mutate {
  remove_field ⇒ "[user][location]"
 }
 # Step 3: Convert numeric fields to proper types
 mutate {
  convert ⇒ {
   "[user][user_id]" ⇒ "integer"
   "book_rating" ⇒ "integer"
  }
 }
 # Step 4: Handle age field - convert to integer or null
 if [user][age] == "" or [user][age] == "null" {
  mutate { replace ⇒ { "[user][age]" ⇒ nil } }
 } else {
  mutate { convert ⇒ { "[user][age]" ⇒ "integer" } }
 }
}
output {
```

```
elasticsearch {
  hosts ⇒ ["http://elasticsearch:9200"]
  index ⇒ "books_dataset"
  template ⇒ "/usr/share/logstash/data/books_template.json"
  template_name ⇒ "books"
  template_overwrite ⇒ true
}
stdout { codec ⇒ rubydebug }
}
```

Dit zie ik nu in kibana (in Dev tools) als ik deze query doe: GET books_dataset/_search

3. Queries en aggregaties

Beantwoord de volgende vragen met behulp van de Elasitcsearch DSL

3.1 De heel eenvoudige:

Hoeveel documenten zijn er in totaal? ⇒ 945287

```
GET books_dataset/_count
```

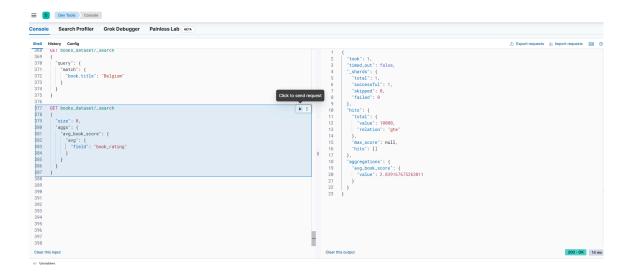
• Zoek alle documenten waarvan de titel "Belgium" bevat. ⇒ 9 documenten bevatten Belgium in de titel.

```
GET books_dataset/_search
{
   "query": {
     "match": {
        "book.title": "Belgium"
      }
   }
}
```

3.2 De eenvoudige:

• Wat is de gemiddelde score van een boek? ⇒ 2.839167675263011

```
GET books_dataset/_search
{
    "size": 0,
    "aggs": {
        "avg_book_score": {
            "avg": {
                "field": "book_rating"
            }
        }
    }
}
```



Wat is de mediaanscore van een boek? ⇒ 0.2591136226760329

```
}
}
}
```

```
| Description |
```

3.3 lets moeilijker:

- Welke gebruiker (user_id) heeft in totaal de meeste scores gepost? Uit welk land komt deze gebruiker? Probeer overbodige velden uit het resultaat te filteren, kijk naar de (voorbeeld) hits sectie hieronder:
- user_id: 11676 en Land van deze gebruiker: "n/a" dus het land is onbekend van deze gebruiker.

```
"hits": [
{
    "_index": "books_dataset",
    "_id": "0123456789-123456",
    "_score": 1,
    "_source": {
        "user": {
            "country": "Examnia",
            "user_id": 123456
        }
    }
```

```
}
]
```

```
GET books_dataset/_search
 "size": 1,
 "aggs": {
  "most_active_user": {
   "terms": {
    "field": "user.user_id",
    "size": 1,
    "order": {
     "_count": "desc"
    }
   },
   "aggs": {
    "top_hit": {
      "top_hits": {
       "size": 1,
       "_source": ["user.user_id", "user.country"]
      }
    }
   }
}
}
```

```
| Constraint | Con
```

3.3 Na aanpassingen:

```
# 3.3 na aanpassingen:
GET books_dataset/_search
 "size": 1,
 "_source": ["user.user_id", "user.country"],
 "aggs": {
  "most_active_user": {
   "terms": {
     "field": "user.user_id",
     "size": 1,
     "order": {
      "_count": "desc"
     }
   },
    "aggs": {
     "top_hit": {
      "top_hits": {
       "size": 1,
       "_source": ["user.user_id", "user.country"]
      }
     }
```

```
}
}
```

Resultaat: 20 overbodige lijntjes minder

3.4 Moeilijker:

• Welk boek heeft de hoogste gemiddelde score binnen de 10 meest beoordeelde boeken? De output zou er ongeveer als volgt kunnen uitzien:

```
{
  "took": 2,
  "timed_out": false,
  "_shards": {
     "total": 1,
     "succesfull": 1,
     "skipped": 0,
     "failed": 0
  },
  "hits": {
     "total": {
       "value":10000,
       "relation": "gte"
     },
     "max_score": null,
     "hits": []
  },
```

```
"<replaced>": {
    "<some_name>": {
       "doc_count_error_upper_bound": 0,
       "sum_other_doc_count": 1021954,
       "b...": [
         {
           "key": "0123456789",
           "doc_count": 123,
           "avg_score": {
              "value": 4.567
           }
         }
       ]
    }
  }
}
```

```
GET books_dataset/_search
 "size": 0,
 "aggs": {
  "most_reviewed_books": {
   "terms": {
    "field": "book.title.keyword",
    "size": 10,
    "order": {
     "_count": "desc" // Sorteer op aantal beoordelingen (doc_count)
    }
   },
   "aggs": {
    "avg_score": {
     "avg": {
       "field": "book_rating"
     }
    }
  }
```

```
}
}
```

```
| Search Profiler | Grok Debugger | Painless Lab was
| Search Profiler | Grok Debugger | Painless Lab was
| Search Profiler | Grok Debugger | Painless Lab was
| Search Profiler | Search | Sear
```

dus het is boek: **The Da Vinci Code** die 818 keer beoordeeld is en de gemiddelde score **4.68**

Boek	Aantal beoordelingen	Gemiddelde score
Wild Animus	2311	1.03
The Lovely Bones: A Novel	1191	4.48
The Da Vinci Code	818	4.68
Bridget Jones's Diary	762	3.58
The Nanny Diaries: A Novel	760	3.58
A Painted House	755	3.16
The Secret Life of Bees	708	4.46

Divine Secrets of the Ya-Ya Sisterhood: A Novel	686	3.42
The Red Tent (Bestselling Backlist)	661	4.32
Angels & Demons	616	3.72

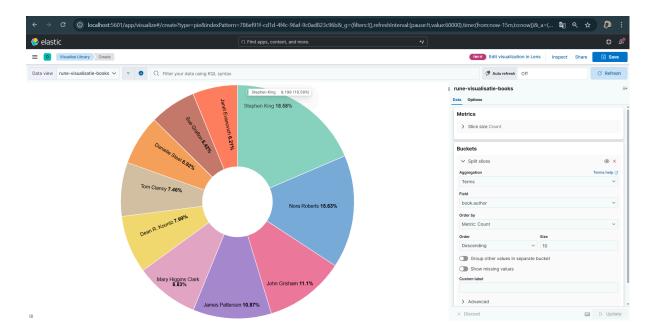
4. Visualisatie

Probeer onderstaande visualisatie na te maken. Wat toont deze eigenlijk?

stap 1: ik heb hem aangemaakt in "Visualize library" dan "Create data view" dan books_dataset* . Daarna heb ik geen time filter field name gedaan. en daarna Create data view

stap 2: alle stappen om dus je pi op te splitsen via terms aggregation per author en dan 10 geselecteerd:

Deze toont welke auteur de meeste boeken heeft geschreven.



5. Clusterstatus

Wat is de status van de cluster? Let uit!

Ik doe deze queries:

```
GET _cluster/health
{
 "cluster_name": "docker-cluster",
 "status": "yellow",
 "timed_out": false,
 "number_of_nodes": 1,
 "number_of_data_nodes": 1,
 "active_primary_shards": 32,
 "active_shards": 32,
 "relocating_shards": 0,
 "initializing_shards": 0,
 "unassigned_shards": 2,
 "unassigned_primary_shards": 0,
 "delayed_unassigned_shards": 0,
 "number_of_pending_tasks": 0,
 "number_of_in_flight_fetch": 0,
 "task_max_waiting_in_queue_millis": 0,
 "active_shards_percent_as_number": 94.11764705882352
}
```

GET _cat/indices

```
iJZ\
green open .internal.alerts-transform.health.alerts-default-000001
green open .internal.alerts-observability.logs.alerts-default-000001
                                                                         xNF
green open .internal.alerts-observability.uptime.alerts-default-000001
                                                                           ۷q
green open .internal.alerts-ml.anomaly-detection.alerts-default-000001
green open .internal.alerts-observability.slo.alerts-default-000001
                                                                         CbvI
green open .internal.alerts-observability.apm.alerts-default-000001
                                                                          4aa
green open .internal.alerts-default.alerts-default-000001
                                                                     ZS4-x1c
green open .internal.alerts-observability.metrics.alerts-default-000001
                                                                           MI
green open .internal.alerts-ml.anomaly-detection-health.alerts-default-0000(
green open internal.alerts-observability.threshold.alerts-default-000001
                                                                            Ν
```

green open .internal.alerts-security.alerts-default-000001 DRchjZoyellow open books_dataset HDYB_SrEQgC_aTz green open .internal.alerts-stack.alerts-default-000001 do5Uqho

GET _cat/shards

.kibana_entities-definitions-1	0 p S	TARTE	ΞD	44	26	.7k
.internal.alerts-observability.slo.alerts-default-	000001	0	p STA	٩RT	ED	
.kibana_usage_counters_8.18.1_001	C	p STA	ARTED)	75	1
.internal.alerts-default.alerts-default-000001		0 p S	START	ED		0
.internal.alerts-observability.uptime.alerts-defa	ault-0000	01	0 p S	TAF	RTE)
.internal.alerts-stack.alerts-default-000001		0 p S	TART	ED		0
.internal.alerts-ml.anomaly-detection-health.al	erts-defa	ult-00	0001 () p :	STA	RT
.slo-observability.summary-v3.4	0	p STA	RTED		0	2
.kibana-siem-rule-migrations-prebuiltrules		0 p s	START	ED		0
.kibana_task_manager_8.18.1_001	0	p STA	RTED		34	12
.internal.alerts-observability.metrics.alerts-def	ault-0000	001	0 p S	TAF	RTE)
.internal.alerts-observability.threshold.alerts-d	efault-00	0001	0 p :	STA	RTE	D
.slo-observability.sli-v3.4	0 p ST	ARTE)	0	249)b
.kibana_ingest_8.18.1_001	0 p S	TARTE!	D	0	249	9b
.kibana_alerting_cases_8.18.1_001	0	STAF	RTED		1 6	6.9
.kibana-siem-rule-migrations-integrations		0 p S	START	ED		0
.kibana_analytics_8.18.1_001	0 p S	TARTE	ΞD	7	2.3	Bml
.internal.alerts-observability.apm.alerts-defaul	t-000001		0 p S	TAR	TED)
.dslogs-deprecation.elasticsearch-default-20	025.05.12	-0000	01 (0 p :	STA	RT
.internal.alerts-security.alerts-default-000001		0 p :	START	ED		0
.ds-ilm-history-7-2025.05.12-000001		0 p S	ΓARTE	D	3	9
.apm-source-map	0 p ST	ARTEC)	0	249	b
.internal.alerts-observability.logs.alerts-defaul	t-000001	(D p ST	ART	ED	
.kibana_security_solution_8.18.1_001	0	p STA	RTED		3	3
.kibana_8.18.1_001	0 p STAF	TED	30	98	.3kb	9 6
books_dataset	0 p STAR	TED	9452	87	293	3m
books_dataset	0 r UNAS	SIGNE	ED .			
books_dataset	0 r UNAS	SIGNE	ED .			
.internal.alerts-transform.health.alerts-default-	-000001	(0 p ST	'AR1	ΓED	
.slo-observability.summary-v3.4.temp		0 p S	TARTE	ΞD		0

.apm-agent-configuration0 p STARTED0 249.internal.alerts-ml.anomaly-detection.alerts-default-0000010 p STARTED.apm-custom-link0 p STARTED0 249b.async-search0 p STARTED7 25.4kb 25.ds-.kibana-event-log-ds-2025.05.12-0000010 p STARTED

Clusterstatus en Uitleg

Samenvatting van de Gegevens

• Cluster naam: docker-cluster

• Status: yellow

Aantal nodes: 1

Aantal datanodes: 1

Aantal actieve primaire shards: 32

• Aantal actieve shards in totaal: 32

Aantal unassigned shards: 2

(2 onverdeelde replica shards van books_dataset index)

Betekenis van Status yellow

De status yellow betekent:

- · Alle primaire shards zijn beschikbaar en actief.
 - De data is volledig leesbaar en toegankelijk.
- · Niet alle replica shards zijn beschikbaar.
 - Er zijn replica's die niet kunnen worden toegewezen, meestal omdat er maar één node actief is.

Dit is **normaal gedrag** voor een **single-node cluster**:

- Elasticsearch kan replica's niet toewijzen aan dezelfde node als de primaire shard.
- Dit voorkomt dat een fout in die ene node ook meteen de replica's uitschakelt, wat geen echte failover zou zijn.

■ Details uit cat/indices en cat/shards

- De **index** books_dataset heeft:
 - 1 primaire shard (pstarted) Actief en gezond.
 - **2 replica shards (runassigned)** Niet toegewezen omdat er maar 1 node is.

Alle andere interne indices hebben geen replica's (1 primaire shard, 0 replica's), en staan daarom **op** green, wat correct is.

Is dit een probleem?

- Voor een single-node test- of ontwikkelomgeving is dit geen probleem.
- Voor een productieomgeving zou dit wél een risico zijn, omdat je geen redundantie hebt.